

# Глубинное обучение в анализе графовых данных

## 3. Эмбединги

в предыдущих сериях...

# Создание признаков

Графы - объекты сложные, нужно придумать как делать признаки

Как и для задач, разобрали признаки (feature engineering) для

- вершин
- связей
- графов

# Признаки для вершин

- степень вершины
- центральность
- коэффициент кластеризации
- графлеты

# Признаки для связей

- дистанция
- локальное пересечение
- глобальное пересечение

# Признаки для графов

- графлетовые ядра
- WL ядра

Эмбеддинги

# Мотивация

Вручную создавать признаки требует определенного погружения в задачу. На этапе построения не всегда понятно, какие точно стоит выбирать, какие помогут улучшить алгоритмы машинного обучения.


Нужно научиться выделять удобные признаки более “общими” способами. В этом нам смогут помочь **эмбединги**.



# Эмбединги


Эмбединги вершин - векторы, суммаризирующие позицию вершины в графе и локальное соседство

По сути хотим получить проекцию в пространство, где геометрические соотношения векторов будут отображать связи в оригинальном графе



# Эмбединги

Перед нами стоит задача как-то закодировать вершины, чтобы похожесть в эмбединговом пространстве позволяла аппроксимировать похожесть в графе



# Encoder

Encoder - функция, которая проецирует вершины графа в эмбединговое пространство

$$v \rightarrow \mathbf{z}_v \quad \text{ENC} : \mathcal{V} \rightarrow \mathbb{R}^d$$

$$\text{ENC}(v) = \mathbf{Z}[v]$$

# Decoder

Decoder - функция, по представлению реконструирующая оригинал и связи

В простом случае парный декодировщик позволяет спрогнозировать связаны ли две вершины в графе

$$\text{DEC} : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}^+$$


$$\text{DEC}(\text{ENC}(u), \text{ENC}(v)) = \text{DEC}(\mathbf{z}_u, \mathbf{z}_v) \approx \mathbf{S}[u, v].$$

# Парадигма

1. encoder переводит вершины в пространство эмбедингов
2. определяем каким-то образом похожесть вершин в графе
3. decoder переводит эмбединги в степень похожести
4. оптимизируем параметры encoder'а для достижения следующей цели

$$\text{similarity}(u, v) \approx \mathbf{z}_v^T \mathbf{z}_u$$

# Парадигма



# Оптимизация

Задачу обучения декодировщика можно описать как задачу минимизации следующего функционала:

$$\mathcal{L} = \sum_{(u,v) \in \mathcal{D}} \ell(\text{DEC}(\mathbf{z}_u, \mathbf{z}_v), \mathbf{S}[u, v])$$

# Подходы к созданию эмбеддингов



# Основанные на факторизации матриц смежности

- Laplacian eigenmaps
- Inner-product methods

# Laplacian eigenmaps

$$\text{DEC}(\mathbf{z}_u, \mathbf{z}_v) = \|\mathbf{z}_u - \mathbf{z}_v\|_2^2$$

$$\mathcal{L} = \sum_{(u,v) \in \mathcal{D}} \text{DEC}(\mathbf{z}_u, \mathbf{z}_v) \cdot \mathbf{S}[u, v].$$

## Inner-product methods

$$\text{DEC}(\mathbf{z}_u, \mathbf{z}_v) = \mathbf{z}_u^\top \mathbf{z}_v$$

$$\mathcal{L} = \sum_{(u,v) \in \mathcal{D}} \|\text{DEC}(\mathbf{z}_u, \mathbf{z}_v) - \mathbf{S}[u, v]\|_2^2.$$

$$\mathcal{L} \approx \|\mathbf{Z}\mathbf{Z}^\top - \mathbf{S}\|_2^2$$

# Обзор

Method	Decoder	Similarity measure	Loss function
Lap. Eigenmaps	$\ \mathbf{z}_u - \mathbf{z}_v\ _2^2$	general	$\text{DEC}(\mathbf{z}_u, \mathbf{z}_v) \cdot \mathbf{S}[u, v]$
Graph Fact.	$\mathbf{z}_u^\top \mathbf{z}_v$	$\mathbf{A}[u, v]$	$\ \text{DEC}(\mathbf{z}_u, \mathbf{z}_v) - \mathbf{S}[u, v]\ _2^2$
GraRep	$\mathbf{z}_u^\top \mathbf{z}_v$	$\mathbf{A}[u, v], \dots, \mathbf{A}^k[u, v]$	$\ \text{DEC}(\mathbf{z}_u, \mathbf{z}_v) - \mathbf{S}[u, v]\ _2^2$
HOPE	$\mathbf{z}_u^\top \mathbf{z}_v$	general	$\ \text{DEC}(\mathbf{z}_u, \mathbf{z}_v) - \mathbf{S}[u, v]\ _2^2$
DeepWalk	$\frac{e^{\mathbf{z}_u^\top \mathbf{z}_v}}{\sum_{k \in \mathcal{V}} e^{\mathbf{z}_u^\top \mathbf{z}_k}}$	$p_{\mathcal{G}}(v u)$	$-\mathbf{S}[u, v] \log(\text{DEC}(\mathbf{z}_u, \mathbf{z}_v))$
node2vec	$\frac{e^{\mathbf{z}_u^\top \mathbf{z}_v}}{\sum_{k \in \mathcal{V}} e^{\mathbf{z}_u^\top \mathbf{z}_k}}$	$p_{\mathcal{G}}(v u)$ (biased)	$-\mathbf{S}[u, v] \log(\text{DEC}(\mathbf{z}_u, \mathbf{z}_v))$

# Случайные блуждания

Обсужденные ранее методы как правило определяют  $S$  как некую полиномиальную функцию, и оптимизируется похожесть произведения двух эмбеддингов и  $S[u, v]$

В последнее время успешными начинают быть методы, которые связаны с вероятностным подходом к похожести эмбеддингов, основанными на том, как часто вершины взаимно встречаются на случайных проходах

# Случайные блуждания

$$\text{DEC}(\mathbf{z}_u, \mathbf{z}_v) \triangleq \frac{e^{\mathbf{z}_u^\top \mathbf{z}_v}}{\sum_{v_k \in \mathcal{V}} e^{\mathbf{z}_u^\top \mathbf{z}_k}}$$

# Случайные блуждания

$$\text{DEC}(\mathbf{z}_u, \mathbf{z}_v) \triangleq \frac{e^{\mathbf{z}_u^\top \mathbf{z}_v}}{\sum_{v_k \in \mathcal{V}} e^{\mathbf{z}_u^\top \mathbf{z}_k}} \\ \approx p_{\mathcal{G}, T}(v|u)$$

# Случайные блуждания

$$\mathcal{L} = \sum_{(u,v) \in \mathcal{D}} -\log(\text{DEC}(\mathbf{z}_u, \mathbf{z}_v))$$



node2vec (negative sampling)

$$\mathcal{L} = \sum_{(u,v) \in \mathcal{D}} -\log(\sigma(\mathbf{z}_u^\top \mathbf{z}_v)) - \gamma \mathbb{E}_{v_n \sim P_n(\mathcal{V})} [\log(-\sigma(\mathbf{z}_u^\top \mathbf{z}_{v_n}))].$$

LINE

$$\text{DEC}(\mathbf{z}_u, \mathbf{z}_v) = \frac{1}{1 + e^{-\mathbf{z}_u^\top \mathbf{z}_v}}$$

# Альтернативные подходы

- Можно совершать “прыжки” в блужданиях
- `struct2vec`

# Проблемы

- каждая вершина в таком подходе рассматривается индивидуально
- не используют признаки вершин
- не способны работать с новыми вершинами

решим потом) (on the way to GNN)

# Графы знаний (или multi-relational graphs)

Граф -  $G = (V, E)$  ,  $V$  - вершины,  $E$  - ребра

В обычном графе  $e = (u, v)$

В графе знаний  $e = (u, t, v)$

В общем случае на графах знаний решается задача предсказания пропущенных связей, но бывают и задачи классификации вершин

# RESCAL

$$\text{DEC}(u, \tau, v) = \mathbf{z}_u^\top \mathbf{R}_\tau \mathbf{z}_v;$$

$$\begin{aligned} \mathcal{L} &= \sum_{u \in \mathcal{V}} \sum_{v \in \mathcal{V}} \sum_{\tau \in \mathcal{R}} \|\text{DEC}(u, \tau, v) - \mathcal{A}[u, \tau, v]\|^2 \\ &= \sum_{u \in \mathcal{V}} \sum_{v \in \mathcal{V}} \sum_{\tau \in \mathcal{R}} \|\mathbf{z}_u^\top \mathbf{R}_\tau \mathbf{z}_v - \mathcal{A}[u, \tau, v]\|^2, \end{aligned}$$

# Стандартные функции потерь

- cross-entropy with negative sampling
- max-margin loss

# Cross-entropy with negative sampling

$$\mathcal{L} = \sum_{(u, \tau, v) \in \mathcal{E}} -\log(\sigma(\text{DEC}(\mathbf{z}_u, \tau, \mathbf{z}_v))) - \gamma \mathbb{E}_{v_n \sim P_{n,u}(\mathcal{V})} [\log(\sigma(-\text{DEC}(\mathbf{z}_u, \tau, \mathbf{z}_{v_n})))]$$

$$\mathcal{L} = \sum_{(u, \tau, v) \in \mathcal{E}} \left( -\log(\sigma(\text{DEC}(\mathbf{z}_u, \tau, \mathbf{z}_v))) - \sum_{v_n \in \mathcal{P}_{n,u}} [\log(\sigma(-\text{DEC}(\mathbf{z}_u, \tau, \mathbf{z}_{v_n})))] \right)$$



## Max-margin loss

$$\mathcal{L} = \sum_{(u, \tau, v) \in \mathcal{E}} \sum_{v_n \in \mathcal{P}_{n, u}} \max(0, -\text{DEC}(\mathbf{z}_u, \tau, \mathbf{z}_v) + \text{DEC}(\mathbf{z}_u, \tau, \mathbf{z}_{v_n}) + \Delta)$$

# Обзор

Name	Decoder	Relation Parameters
RESCAL	$\mathbf{z}_u^\top \mathbf{R}_\tau \mathbf{z}_v$	$\mathbf{R}_\tau \in \mathbb{R}^{d \times d}$
TransE	$-\ \mathbf{z}_u + \mathbf{r}_\tau - \mathbf{z}_v\ $	$\mathbf{r}_\tau \in \mathbb{R}^d$
TransX	$-\ g_{1,\tau}(\mathbf{z}_u) + \mathbf{r}_\tau - g_{2,\tau}(\mathbf{z}_v)\ $	$\mathbf{r}_\tau \in \mathbb{R}^d, g_{1,\tau}, g_{2,\tau} \in \mathbb{R}^d \rightarrow \mathbb{R}^d$
DistMult	$\langle \mathbf{z}_u, \mathbf{r}_\tau, \mathbf{z}_v \rangle$	$\mathbf{r}_\tau \in \mathbb{R}^d$
ComplEx	$\text{Re}(\langle \mathbf{z}_u, \mathbf{r}_\tau, \bar{\mathbf{z}}_v \rangle)$	$\mathbf{r}_\tau \in \mathbb{C}^d$
RotatE	$-\ \mathbf{z}_u \circ \mathbf{r}_\tau - \mathbf{z}_v\ $	$\mathbf{r}_\tau \in \mathbb{C}^d$

# Translational Decoders

$$\text{DEC}(\mathbf{z}_u, \tau, \mathbf{z}_v) = -\|\mathbf{z}_u + \mathbf{r}_\tau - \mathbf{z}_v\|$$

$$\text{DEC}(\mathbf{z}_u, \tau, \mathbf{z}_v) = -\|g_{1,\tau}(\mathbf{z}_u) + \mathbf{r}_\tau - g_{2,\tau}(\mathbf{z}_v)\|$$

$$\text{DEC}(\mathbf{z}_u, \tau, \mathbf{z}_v) = -\|(\mathbf{z}_u - \mathbf{w}_r^\top \mathbf{z}_u \mathbf{w}_r) + \mathbf{r}_\tau - (\mathbf{z}_v - \mathbf{w}_r^\top \mathbf{z}_v \mathbf{w}_r)\|$$

# Multi-linear

$$\begin{aligned}\text{DEC}(\mathbf{z}_u, \tau, \mathbf{z}_v) &= \langle \mathbf{z}_u, \mathbf{r}_\tau, \mathbf{z}_v \rangle \\ &= \sum_{i=1}^d \mathbf{z}_u[i] \times \mathbf{r}_\tau[i] \times \mathbf{z}_v[i] \\ &= \langle \mathbf{z}_v, \mathbf{r}_\tau, \mathbf{z}_u \rangle \\ &= \text{DEC}(\mathbf{z}_v, \tau, \mathbf{z}_u).\end{aligned}$$

# Complex


$$\begin{aligned}\text{DEC}(\mathbf{z}_u, \tau, \mathbf{z}_v) &= \text{Re}(\langle \mathbf{z}_u, \mathbf{r}_\tau, \bar{\mathbf{z}}_v \rangle) \\ &= \text{Re}\left(\sum_{i=1}^d \mathbf{z}_u[i] \times \mathbf{r}_\tau[i] \times \bar{\mathbf{z}}_v[j]\right)\end{aligned}$$

$$\text{DEC}(\mathbf{z}_u, \tau, \mathbf{z}_v) = -\|\mathbf{z}_u \circ \mathbf{r}_\tau - \mathbf{z}_v\|,$$

# Свойства

- симметрия (асимметрия)
- инверсионность
- КОМПОЗИТНОСТЬ

# Эмбеддинги графов




Среднее

$$\mathbf{z}_G = \sum_{v \in G} \mathbf{z}_v$$



# Виртуальная вершина



# Анонимные случайные блуждания

1. Сэмплируем анонимные случайные блуждания и отображаем граф как частоты появления случайных блужданий
2. Обучаем эмбединги графа вместе с анонимными случайными блужданиями