

Глубинное обучение в анализе графовых данных

5. Передача информации

в предыдущих сериях...

Свойства декодеров

- симметрия (асимметрия)
- инверсионность
- КОМПОЗИТНОСТЬ

$$\begin{aligned}\text{DEC}(\mathbf{z}_u, \tau, \mathbf{z}_v) &= \text{DEC}(\mathbf{z}_v, \tau, \mathbf{z}_u) \\ -\|\mathbf{z}_u + \mathbf{r}_\tau - \mathbf{z}_v\| &= -\|\mathbf{z}_v + \mathbf{r}_\tau - \mathbf{z}_u\| \\ &\Rightarrow \\ -\mathbf{r}_\tau &= \mathbf{r}_\tau \\ &\Rightarrow \\ \mathbf{r}_\tau &= 0.\end{aligned}$$

PageRank

Алгоритм ранжирования страниц в интернете

С помощью метода power iteration решаем задачу вида $r = Gr$

При этом в “гугл” матрице имеется dumping factor β , который позволяет решить проблему циклов в графе, и также тупики предобрабатываются заранее

Передача информации

Вспомним об эмбедингах

Эмбединги вершин позволяют получать удобные для обучения представления вершин

Раньше мы смотрели эмбединг вида $ENC(v) = Z[i]$ (просто брали эмбединг вершины из эмбедингового пространства)

Подход имел ряд проблем - тяжело считается, получая новые вершины эмбединга для них не найти, не используются признаки внутри вершины

Эмбеддинги и GNN

$$\text{ENC}(v) = \text{MLP}$$

Глубинные графовые энкодеры

Общая схема очень похожа на классические DL подходы

INPUT: граф


Проходит через свертки, функции активации, регуляризационные юниты, по итогу получаются эмбединги вершин

Таким подходом можно работать еще и подграфами (и графами)

Задачи


- Классификация вершин
- Предсказание связей
- Детекция сообществ
- Похожесть сетей

Основная проблема



Networks

VS.



Images



Text

Классический DL

- Решаем задачу $\min_{\Theta} \mathcal{L}(\mathbf{y}, f(\mathbf{x}))$
- f - линейный слой, сеть, графовая сеть
- Сэмплируем минибатч x
- Делаем forward pass (считаем L)
- Делаем backward pass ($\nabla_{\mathbf{w}} \mathcal{L}$) используя chain rule
- С помощью стохастического градиентного спуска оптимизируем

$$f(\mathbf{x}) = W_2(W_1\mathbf{x})$$

$$h(x) = W_1\mathbf{x}$$

$$g(z) = W_2z$$

$$\frac{df}{dx} = \frac{dg}{dh} \cdot \frac{dh}{dx}$$


$$\mathbf{x}^{(l+1)} = \sigma(W_l \mathbf{x}^{(l)} + b^l)$$

О графах


- V - вершины
- A - бинарная матрица смежности
- $X \in \mathbb{R}^{m \times |V|}$ - матрица признаков вершин
- v - вершина в V , $N(v)$ - соседство вершины v

Наивный подход:

Наивный подход



	A	B	C	D	E	Feat	
A	0	1	1	1	0	1	0
B	1	0	0	1	1	0	0
C	1	0	0	1	0	0	1
D	1	1	1	0	1	1	1
E	0	1	0	1	0	1	0



?

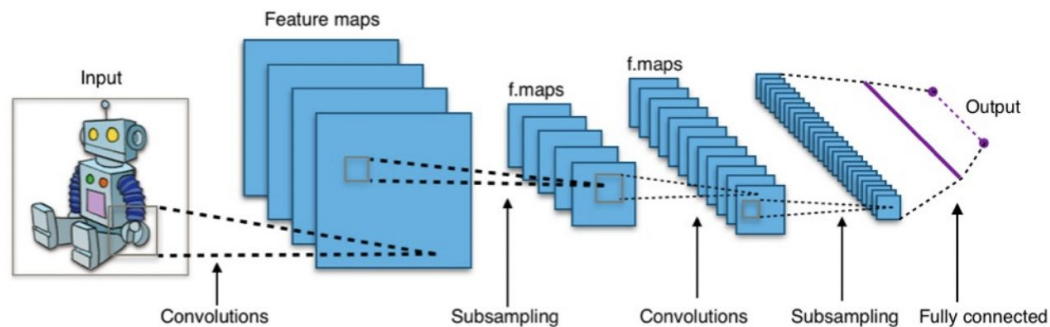

Проблемы наивного подхода

- Долго
- Зависит от порядка вершин
- На разных графах работать не будет


Интуиция

Цель - генерализовать какие-то топологические мотивы с помощью некоторого аналога “сверток”


Обычные свертки



Проблема с применением обычных сверток




or this:




Инвариант перестановок


Order plan 1




Node features X_1




Adjacency matrix A_1




Order plan 2




Node features X_2



Adjacency matrix A_2




Вершины



$f(A_1, X_1) =$



A		
B		
C		
D		
E		
F		










$f(A_2, X_2) =$

A		
B		
C		
D		
E		
F		



Основная идея - агрегация



Агрегация соседей



Как считать



Как считать

